

Reconhecimento de Expressões Faciais com Redes Neurais Convolucionais: Uma Abordagem Interpretável sobre a Base FER2013

Caio Vinícius Maciel Delgado

Engenharia de Computação

Universidade Tecnológica Federal do Paraná

Apucarana, Brasil

email@alunos.utfpr.edu.br

Guilherme Pança Franco

Engenharia de Computação

Universidade Tecnológica Federal do Paraná

Apucarana, Brasil

guilhermefranco.2003@alunos.utfpr.edu.br

João Pedro Garcia Bronharo

Engenharia de Computação

Universidade Tecnológica Federal do Paraná

Apucarana, Brasil

email@alunos.utfpr.edu.br

Resumo—O reconhecimento automático de expressões faciais é uma tarefa central em visão computacional, com aplicações em interação humano-computador, computação afetiva e sistemas assistivos. Este trabalho apresenta o desenvolvimento de um sistema de classificação de emoções a partir de imagens faciais utilizando uma Rede Neural Convolucional (CNN) treinada do zero sobre a base FER2013, restrita a cinco classes de emoção (raiva, felicidade, neutralidade, tristeza e surpresa). O modelo proposto, operando sobre imagens em escala de cinza de 48x48 pixels, alcançou acurácia Top-1 de 72,13% e acurácia Top-2 de 88,66% no conjunto de teste, resultados competitivos para uma arquitetura compacta e dados desbalanceados. Além da avaliação quantitativa por meio de matriz de confusão e métricas por classe, aplicamos a técnica de interpretabilidade SHAP (SHapley Additive exPlanations) para investigar as regiões faciais que mais influenciam as decisões do modelo, evidenciando padrões consistentes de confusão entre emoções de valência negativa. Os resultados demonstram a viabilidade de uma abordagem leve e interpretável para o reconhecimento de expressões faciais.

Index Terms—reconhecimento de expressões faciais, redes neurais convolucionais, aprendizado profundo, FER2013, interpretabilidade, SHAP

I. INTRODUÇÃO

A expressão facial é um dos canais mais ricos da comunicação humana não verbal, transmitindo estados emocionais que complementam e por vezes contradizem a linguagem falada. Dotar máquinas da capacidade de reconhecer essas expressões abre caminho para sistemas mais empáticos e responsivos, com aplicações que vão desde a interação humano-computador e jogos digitais até o monitoramento de bem-estar, a análise de engajamento educacional e ferramentas de apoio a pessoas com dificuldades de percepção social.

Apesar dos avanços recentes em aprendizado profundo, o Reconhecimento de Expressões Faciais (*Facial Expression Recognition* – FER) permanece desafiador. As principais dificuldades incluem a alta variabilidade intraclasse (uma mesma

emoção é expressa de formas distintas entre indivíduos), a similaridade interclasse (emoções diferentes podem produzir configurações faciais semelhantes), variações de iluminação, pose e oclusão, e o desbalanceamento das bases de dados públicas.

Este trabalho tem como objetivo o desenvolvimento de um software capaz de classificar expressões faciais em imagens estáticas. Optou-se por construir uma Rede Neural Convolucional (CNN) treinada do zero, em vez de recorrer a modelos pré-treinados de grande porte, com a finalidade de obter uma solução compacta, computacionalmente acessível e adequada ao escopo de um projeto acadêmico. Como diferencial, incorporamos uma análise de interpretabilidade baseada na técnica SHAP, buscando não apenas medir *o quão bem* o modelo classifica, mas também compreender *por que* ele toma determinadas decisões e onde erra.

O restante deste artigo está organizado da seguinte forma. A Seção II discute trabalhos relacionados. A Seção III descreve a metodologia, incluindo a base de dados, o pré-processamento, a arquitetura da rede e o protocolo de treinamento. A Seção IV apresenta e discute os resultados quantitativos e a análise de interpretabilidade. Por fim, a Seção V traz as conclusões e perspectivas de trabalhos futuros.

II. TRABALHOS RELACIONADOS

A base FER2013, introduzida em uma competição de aprendizado de máquina, tornou-se um dos *benchmarks* mais utilizados para o reconhecimento de expressões faciais [1]. Ela é composta por imagens em escala de cinza de 48x48 pixels rotuladas em sete categorias de emoção. Por sua natureza ruidosa e desbalanceada, a base é reconhecidamente difícil: a concordância entre rotuladores humanos foi estimada por Goodfellow *et al.* em apenas $65\% \pm 5\%$ [1], o que estabelece um teto prático relativamente baixo para o desempenho de

classificadores automáticos. Mesmo arquiteturas profundas e cuidadosamente ajustadas obtêm ganhos limitados sobre esse teto: revisões do estado da arte reportam acurácias da ordem de 71% a 73% para CNNs como VGG, ResNet e Inception isoladas [3], com ensembles maiores e ajuste fino de hiperparâmetros atingindo a faixa de 73% a 75% [3], [4].

As abordagens para FER evoluíram de métodos clássicos, baseados na extração manual de características como *Local Binary Patterns* (LBP) e Histogramas de Gradientes Orientados (HOG) seguidos de classificadores como Máquinas de Vetores de Suporte (SVM), para arquiteturas de aprendizado profundo [2]. As Redes Neurais Convolucionais passaram a dominar a área por aprenderem hierarquias de características diretamente dos pixels [5]. Arquiteturas profundas consagradas, como VGG [6] e ResNet [7], e o uso de *transfer learning* a partir de modelos pré-treinados em grandes bases, são estratégias comuns para elevar a acurácia, como demonstrado na revisão comparativa de Pramerdorfer e Kampel sobre a FER2013 [3].

Paralelamente, cresce a preocupação com a interpretabilidade de modelos de aprendizado profundo, frequentemente tratados como “caixas-pretas”. Métodos de atribuição de importância, como Grad-CAM [12] e SHAP [11], permitem visualizar quais regiões da entrada mais contribuem para uma predição. No contexto de FER, essas técnicas são valiosas para verificar se o modelo se baseia em regiões faciais semanticamente relevantes (olhos, boca, sobrancelhas) ou em artefatos espúrios. Este trabalho situa-se nessa interseção, combinando uma CNN compacta treinada do zero com uma análise de interpretabilidade via SHAP.

III. METODOLOGIA

A. Base de Dados

Utilizou-se a base FER2013, organizada em pastas por classe de emoção. Das sete emoções originais, optou-se por restringir o problema a cinco classes: *angry* (raiva), *happy* (felicidade), *neutral* (neutralidade), *sad* (tristeza) e *surprise* (surpresa). As classes *disgust* (nojo) e *fear* (medo) foram removidas por apresentarem um número significativamente menor de amostras e elevada ambiguidade de rotulação, o que tende a degradar o desempenho global e dificultar a análise.

Após a filtragem, o conjunto de treino totalizou 24.176 imagens e o conjunto de teste 6.043 imagens. Como mostra a Tabela I, referente à distribuição do conjunto de teste, as classes apresentam desbalanceamento relevante: a classe *happy* é a mais representada, enquanto *surprise* é a menos frequente.

B. Pré-processamento e Aumento de Dados

As imagens foram carregadas em escala de cinza, mantendo-se a resolução nativa de 48x48 pixels, e os valores de intensidade dos pixels foram normalizados para o intervalo [0, 1]. Para mitigar o sobreajuste e aumentar a capacidade de generalização, aplicou-se aumento de dados (*data augmentation*) sobre o conjunto de treino, com transformações aleatórias de rotação ($\pm 10\%$), zoom ($\pm 10\%$) e espelhamento horizontal.

Tabela I
DISTRIBUIÇÃO DE AMOSTRAS DO CONJUNTO DE TESTE POR CLASSE

Classe	Amostras (teste)
angry	958
happy	1.774
neutral	1.233
sad	1.247
surprise	831
Total	6.043

Para tratar o desbalanceamento entre classes, foram calculados pesos por classe de forma balanceada (inversamente proporcionais à frequência de cada classe) e fornecidos à função de custo durante o treinamento, de modo a penalizar mais fortemente os erros nas classes minoritárias.

C. Arquitetura da Rede

A arquitetura proposta é uma CNN sequencial composta por três blocos convolucionais seguidos de um bloco totalmente conectado, conforme resumido na Tabela II. Cada bloco convolucional contém duas camadas de convolução com filtros 3×3 e ativação ReLU, intercaladas por normalização em lote (*Batch Normalization*) [8], seguidas de uma camada de *max pooling* e de *dropout* [9]. O número de filtros cresce progressivamente (64, 128 e 256) à medida que a resolução espacial diminui, permitindo à rede capturar características cada vez mais abstratas.

A normalização em lote acelera e estabiliza o treinamento, enquanto as camadas de *dropout*, com taxas crescentes (0,25, 0,30 e 0,40 nos blocos convolucionais e 0,50 na camada densa), atuam como regularizadores. A camada de saída é densa com ativação *softmax*, produzindo uma distribuição de probabilidade sobre as cinco classes.

No total, a arquitetura possui **3.509.701 parâmetros** (3.507.397 treináveis e 2.304 não treináveis, referentes às estatísticas das camadas de normalização em lote), ocupando aproximadamente 13,4 MB. Trata-se de um modelo compacto quando comparado a arquiteturas profundas consagradas como VGG16 (mais de 130 milhões de parâmetros), o que favorece tanto o tempo de treinamento quanto a viabilidade de implantação em ambientes com recursos computacionais limitados.

D. Protocolo de Treinamento

O modelo foi treinado utilizando o otimizador Adam [10], com taxa de aprendizado inicial de 10^{-3} , e função de custo de entropia cruzada categórica. O tamanho de lote (*batch size*) foi de 64 e o treinamento foi configurado para até 30 épocas.

Duas estratégias de *callback* foram empregadas para otimizar o processo. A primeira, *Early Stopping*, monitora a perda de validação e interrompe o treinamento caso não haja melhora por 10 épocas consecutivas, restaurando os melhores pesos obtidos. A segunda, *ReduceLROnPlateau*, reduz a taxa de aprendizado pela metade quando a perda de validação estagna por 5 épocas, permitindo um ajuste fino mais delicado nas etapas finais.

Tabela II
RESUMO DA ARQUITETURA DA CNN PROPOSTA

Bloco	Camadas	Saída
Entrada	Imagem em escala de cinza	$48 \times 48 \times 1$
Conv 1	2×[Conv 3×3 , 64 + BN] MaxPool + Dropout(0,25)	$48 \times 48 \times 64$ $24 \times 24 \times 64$
Conv 2	2×[Conv 3×3 , 128 + BN] MaxPool + Dropout(0,30)	$24 \times 24 \times 128$ $12 \times 12 \times 128$
Conv 3	2×[Conv 3×3 , 256 + BN] MaxPool + Dropout(0,40)	$12 \times 12 \times 256$ $6 \times 6 \times 256$
Densa	Flatten	9216
	Dense 256 + BN + Dropout(0,50)	256
Saída	Dense + Softmax	5

Na prática, o treinamento percorreu as 30 épocas completas sem que o critério de *Early Stopping* fosse acionado, e a taxa de aprendizado permaneceu fixa em 10^{-3} durante todo o processo, indicando que o *ReduceLROnPlateau* também não chegou a atuar. As Figs. 1 e 2 mostram, respectivamente, a evolução da perda e da acurácia nos conjuntos de treino e validação ao longo das épocas. As curvas de treino e validação permanecem próximas durante todo o processo, sem o afastamento característico de sobreajuste, o que indica que a combinação de *dropout*, normalização em lote e aumento de dados foi eficaz na regularização do modelo. Observa-se ainda que a perda de validação ainda apresentava leve tendência de queda ao final da época 30, sugerindo que um número maior de épocas ou um agendamento mais agressivo da taxa de aprendizado poderiam produzir ganhos adicionais de desempenho.




Figura 1. Evolução da perda (*loss*) nos conjuntos de treino e validação ao longo das 30 épocas de treinamento.




Figura 2. Evolução da acurácia nos conjuntos de treino e validação ao longo das 30 épocas de treinamento.

Em termos de custo computacional, cada época levou em média entre 15 e 20 segundos em GPU (excetuando a primeira época, mais lenta devido à inicialização), totalizando um tempo de treinamento da ordem de 10 minutos. Esse custo reduzido reforça o argumento de que a solução proposta é computacionalmente acessível, podendo ser treinada e reproduzida sem a necessidade de infraestrutura especializada.

E. Interpretabilidade com SHAP

Como diferencial deste trabalho, empregou-se a técnica SHAP (*SHapley Additive exPlanations*) [11] para interpretar as decisões do modelo. O SHAP atribui a cada *pixel* de entrada um valor de importância que quantifica sua contribuição para a predição de uma dada classe, fundamentado na teoria dos valores de Shapley da teoria dos jogos cooperativos.

Utilizou-se o *GradientExplainer*, adequado a redes neurais, com um conjunto de *background* composto por 100 imagens de treino. A análise foi direcionada especialmente às amostras classificadas incorretamente, permitindo visualizar quais regiões faciais levaram o modelo ao erro e oferecendo uma interpretação qualitativa dos padrões de confusão entre classes.

IV. RESULTADOS E DISCUSSÃO

A. Desempenho Global

No conjunto de teste, o modelo alcançou acurácia Top-1 de **72,13%** e acurácia Top-2 de **88,66%**. A diferença expressiva entre as duas métricas é reveladora: em quase 89% dos casos, a classe correta está entre as duas mais prováveis segundo o modelo. Isso indica que grande parte dos erros não decorre de predições aleatórias, mas de confusões entre pares de emoções genuinamente semelhantes. Cabe destacar que a acurácia Top-1 obtida supera a concordância média entre anotadores reportada para a FER2013 ($65\% \pm 5\%$) [1] e é diretamente comparável a arquiteturas profundas consagradas: Pramerdorfer e Kampel reportam 71,6% com Inception, 72,4% com ResNet e 72,7% com VGG isoladas sobre as sete classes originais da base [3]. O resultado obtido neste trabalho com uma CNN compacta de 3,5 milhões de parâmetros, treinada

do zero e restrita a cinco classes, posiciona-se, portanto, na mesma faixa de desempenho de arquiteturas substancialmente maiores e mais profundas.

B. Métricas por Classe

A Tabela III apresenta as métricas de precisão (*precision*), revocação (*recall*) e *F1-score* por classe, calculadas a partir da matriz de confusão. Observa-se uma clara estratificação de desempenho: as classes *happy* ($F1 = 0,860$) e *surprise* ($F1 = 0,837$) são reconhecidas com alta confiabilidade, ao passo que *sad* ($F1 = 0,599$), *angry* ($F1 = 0,634$) e *neutral* ($F1 = 0,635$) apresentam desempenho mais modesto.

Tabela III
MÉTRICAS DE DESEMPENHO POR CLASSE NO CONJUNTO DE TESTE

Classe	Precisão	Revocação	F1-Score	Suporte
angry	0,649	0,619	0,634	958
happy	0,864	0,856	0,860	1.774
neutral	0,601	0,674	0,635	1.233
sad	0,626	0,574	0,599	1.247
surprise	0,830	0,844	0,837	831
Média Macro	0,714	0,713	0,713	6.043
Média Ponderada	0,722	0,721	0,721	6.043

Esse comportamento é coerente com a literatura: emoções de forte expressividade facial, como o sorriso (*happy*) e a abertura de olhos e boca (*surprise*), possuem marcadores visuais distintos e fáceis de aprender. Em contraste, *sad*, *angry* e *neutral* compartilham configurações faciais sutis e sobrepostas, o que dificulta a discriminação. A Fig. 3 ilustra essa disparidade em termos de acurácia (revocação) por classe.




Figura 3. Acurácia (revocação) do modelo por classe no conjunto de teste.

C. Análise da Matriz de Confusão

A Fig. 4 apresenta a matriz de confusão do modelo. A diagonal principal, predominante, confirma o acerto majoritário. Os erros, contudo, concentram-se em padrões bem definidos. A classe *sad* é a mais problemática: 283 de suas amostras foram classificadas como *neutral* e 139 como *angry*. De forma simétrica, 220 amostras de *neutral* foram confundidas com *sad*. Há ainda confusão relevante entre *angry* e as classes *neutral* (147) e *sad* (146).




Figura 4. Matriz de confusão do modelo no conjunto de teste. As linhas representam a classe real e as colunas a classe predita.

Esse agrupamento de erros entre *angry*, *sad* e *neutral* forma um “triângulo de confusão” entre emoções de valência negativa ou neutra, todas caracterizadas por baixa intensidade de movimento facial. Já as classes *happy* e *surprise* permanecem bem isoladas, com pouquíssimos erros de e para as demais categorias.

D. Interpretabilidade via SHAP

A análise com SHAP foi direcionada às amostras em que o modelo classificou incorretamente expressões de *angry* como outra emoção. Do lote de validação analisado, identificaram-se 365 imagens nessa condição, distribuídas predominantemente entre *neutral* (147 casos) e *sad* (146 casos), com incidência bem menor para *happy* (40) e *surprise* (32), conforme ilustrado na Fig. 5. Essa distribuição corresponde exatamente à linha da classe *angry* na matriz de confusão (Fig. 4), confirmando que os dois principais focos de confusão do modelo são justamente *neutral* e *sad*.

Para os casos de maior incidência, os mapas SHAP compararam a contribuição dos pixels para a classe real (*angry*) e para a classe predita incorretamente. Em amostras confundidas com *sad*, os mapas de importância para as duas classes apresentaram forte sobreposição espacial, concentrando-se predominantemente na região da boca e do queixo. O mesmo padrão de sobreposição, ainda que mais difuso, foi observado em uma amostra confundida com *neutral*, com regiões de destaque adicionais na altura dos olhos e sobrancelhas. Já em um exemplo confundido com *surprise* – erro bem mais raro, com apenas 32 ocorrências –, a importância dos pixels mostrou-se mais espalhada pelo rosto, sem um foco tão concentrado quanto nos demais casos.

A Fig. 6 ilustra esse padrão para uma amostra real de *angry* classificada como *sad*: os mapas de calor para as duas




Figura 5. Distribuição das classes previstas incorretamente para amostras cuja classe real é *angry*.

classes destacam essencialmente a mesma região da imagem, evidenciando que o modelo extrai evidência visual do mesmo ponto da face ao avaliar hipóteses concorrentes.




Figura 6. Mapas SHAP para uma amostra real de *angry* classificada incorretamente como *sad*. Da esquerda para a direita: imagem original, importância dos pixels para a classe real e importância dos pixels para a classe prevista.

É importante registrar uma ressalva metodológica: nem todas as visualizações geradas durante a análise exibiram corretamente a sobreposição do mapa de calor sobre a imagem original, o que se deveu a uma falha pontual no trecho de código de plotagem. As conclusões aqui relatadas baseiam-se exclusivamente nas visualizações em que a sobreposição foi exibida corretamente, e a quantidade de amostras inspecionadas qualitativamente é pequena, de modo que os padrões descritos devem ser interpretados como evidência ilustrativa, e não como generalização estatística.

Ainda assim, os resultados sugerem que o erro do modelo entre *angry*, *sad* e *neutral* decorre de ambiguidade genuína na expressão facial – as três classes compartilham configurações de baixa intensidade muscular na boca e nas sobrancelhas –, e não de um foco em regiões irrelevantes da imagem, como o fundo ou bordas. Esse achado reforça a validade do que o modelo aprendeu, ao mesmo tempo em que aponta a similaridade visual entre emoções de valência negativa e neutra como o principal fator limitante do desempenho.

V. CONCLUSÃO

Este trabalho apresentou o desenvolvimento de um sistema de reconhecimento de expressões faciais baseado em uma CNN compacta treinada do zero sobre a base FER2013, considerando cinco classes de emoção. O modelo atingiu

acurácia Top-1 de 72,13% e Top-2 de 88,66%, resultados competitivos frente à dificuldade reconhecida da base e à faixa de concordância humana. A análise por classe e a matriz de confusão evidenciaram um padrão consistente de confusão entre as emoções *angry*, *sad* e *neutral*, ao passo que *happy* e *surprise* foram reconhecidas com alta confiabilidade.

O principal diferencial do trabalho residiu na incorporação da técnica de interpretabilidade SHAP, que permitiu compreender os padrões de erro do modelo e confirmar que suas decisões se baseiam em regiões faciais relevantes. Demonstrou-se, assim, a viabilidade de uma solução leve, eficiente e interpretável para o problema.

Como trabalhos futuros, vislumbram-se diversas direções. Como o treinamento atual percorreu as 30 épocas sem acionar o *Early Stopping* e sem que a taxa de aprendizado fosse reduzida pelo *ReduceLROnPlateau*, um primeiro passo natural é estender o número de épocas ou adotar um agendamento mais agressivo da taxa de aprendizado, já que a perda de validação ainda apresentava tendência de queda ao final do treinamento atual. A inclusão das classes *disgust* e *fear*, mediante técnicas mais robustas de balanceamento, ampliaria a abrangência do sistema. A adoção de *transfer learning* a partir de arquiteturas pré-treinadas poderia elevar a acurácia, sobretudo nas classes de pior desempenho. A combinação de características aprendidas pela CNN com metadados ou descritores faciais explícitos representa outra avenida promissora. Por fim, a evolução do sistema para a inferência em tempo real, a partir de fluxo de vídeo, e a integração da detecção facial via *Haar Cascade* já prototipada, aproximariam a solução de cenários práticos de aplicação.

REFERÊNCIAS

- [1] I. J. Goodfellow *et al.*, “Challenges in representation learning: A report on three machine learning contests,” *Neural Networks*, vol. 64, pp. 59–63, 2015. [Online]. Disponível em: arXiv:1307.0414.
- [2] S. Li and W. Deng, “Deep facial expression recognition: A survey,” *IEEE Transactions on Affective Computing*, vol. 13, no. 3, pp. 1195–1215, jul.-set. 2022, doi: 10.1109/TAFFC.2020.2981446.
- [3] C. Pramerdorfer and M. Kampel, “Facial expression recognition using convolutional neural networks: State of the art,” in *Proc. 1st Int. Workshop on Deep Learning for Pattern Recognition (DLPR)*, 2016. [Online]. Disponível em: arXiv:1612.02903.
- [4] Y. Khairuddin and Z. Chen, “Facial emotion recognition: State of the art performance on FER2013,” *arXiv preprint arXiv:2105.03588*, 2021.
- [5] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [6] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015. [Online]. Disponível em: arXiv:1409.1556.
- [7] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
- [8] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *Proc. 32nd Int. Conf. Machine Learning (ICML)*, 2015, pp. 448–456.
- [9] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [10] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2015. [Online]. Disponível em: arXiv:1412.6980.

- [11] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4765–4774.
- [12] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proc. IEEE Int. Conf. Computer Vision (ICCV)*, 2017, pp. 618–626.